

Mode d'emploi et glossaire de première lecture

Le guide suit une progression en spirale : la première lecture donne le problème, les paris et les résultats ; les annexes A à F reviennent ensuite sur les formules, les calculs et leurs limites. Les termes ci-dessous sont des repères, pas un cours préalable. Le document companion avancé traite séparément l'estimation d'état, la recherche opérationnelle et l'apprentissage de politiques.

État latent

État réel supposé exister mais non observé directement.

Hypothèse nulle et p-value

La p-value mesure la rareté du résultat si l'hypothèse d'équivalence était vraie.

Croyance, prior, posterior

Distribution de probabilités ; avant observation = prior, après observation = posterior.

Bootstrap apparié

Rééchantillonnage avec remise des mêmes paires pour mesurer la variabilité de l'effet.

Calibration

Accord entre les probabilités annoncées et les fréquences réellement observées.

Permutation appariée

Échange aléatoire des étiquettes dans chaque paire pour construire une distribution nulle.

Score de Brier

Erreur quadratique d'une prévision probabiliste binaire : $(p - y)^2$.

Holm

Correction progressive qui protège une famille de nombreux tests contre les faux positifs.

ECE et intervalle (bin)

Écart moyen de calibration après regroupement des probabilités proches en intervalles.

Identifiabilité

Possibilité de distinguer les causes cachées à partir des observations disponibles.

Seed

Numéro qui permet de reproduire exactement un même scénario aléatoire.

Modèle mal spécifié

Modèle dont les probabilités supposées ne correspondent pas au monde qui produit les données.

Cellule et appariement

Groupe expérimental ; les politiques sont comparées sur le même scénario, paire par paire.

Cote probabiliste (odds)

Rapport $p/(1 - p)$, utile pour exprimer une mise à jour bayésienne.

Baseline

Méthode de comparaison plus simple ou différente.

Rapport de vraisemblance

Pouvoir d'une observation à favoriser une hypothèse plutôt qu'une autre.

Endpoint

Mesure finale utilisée pour juger un résultat.

VOI / EVI

Valeur attendue de l'information : gain décisionnel attendu d'une preuve, avant son résultat.

ED-POMDP EN CLAIR

Pourquoi distinguer le risque du système de la qualité des preuves,
comment est née la sélection dynamique des tests, et ce que le benchmark a réellement établi

Guide pédagogique français - Document compagnon - Version 1.9

À lire avant le papier scientifique

Le rapport Step 2 Benchmark Close-Out est une conclusion scientifique et un document d'audit. Le présent guide explique le problème, la genèse de l'approche, l'intuition, les deux paris scientifiques, leur tentative de falsification et le sens des résultats. Les annexes A à F approfondissent la contestation du modèle, sa généalogie, la mesurabilité des variables, les données synthétiques, le fonctionnement du code et la mécanique statistique utilisée pour juger un résultat. Certaines notions sont d'abord introduites par leur rôle, puis expliquées et calculées dans les annexes : une seconde lecture est volontairement utile. L'ancienne Annexe G est publiée séparément comme document compagnon avancé. Le guide ne remplace pas les artefacts formels et ne modifie aucun claim.

1. Le problème, en une phrase

Le point de départ

Une décision GO / CONDITIONAL GO / NO-GO dépend de deux incertitudes différentes : (1) le produit est-il réellement risqué ? et (2) les preuves utilisées pour en juger sont-elles fiables, récentes et représentatives ? Les dispositifs de qualité classiques mélangent souvent les deux.

Exemple simple. Une campagne de tests passe avec 98 % de succès. Ce chiffre peut signifier que le système est bon. Mais il peut aussi signifier que les tests sont anciens, que l'environnement ne reproduit pas la production, que les oracles sont incomplets ou que les flux critiques n'ont pas été observés. Le même indicateur peut donc masquer deux réalités opposées.

Pourquoi cela compte pour une Test Authority

- Un indicateur faible peut venir d'un produit mauvais ou d'un dispositif de preuve mauvais.
- Un indicateur rassurant peut être trompeur si la preuve est peu représentative ou peu fraîche.
- Accumuler davantage de tests ne résout pas toujours le problème : il faut parfois chercher une preuve différente, pas une preuve de plus.
- La décision de release doit rester explicable : quel risque résiduel, quelle preuve, quelle incertitude, quel coût et quelle règle de décision ?

2. L'intuition ED-POMDP

ED-POMDP signifie *Evidence-Driven Partially Observable Markov Decision Process*. Derrière ce nom technique, l'idée est simple : la qualité de release est un état partiellement observable, et les tests, revues, traces ou simulations sont des actions choisies pour réduire une incertitude avant de décider.

État réel du système	Qualité des preuves	Test / revue / trace	Croyance mise à jour	GO / CONDITIONAL GO / NO-GO
(caché)	(cachée)	(action)	(probabilités)	(décision)

Le cœur de l'idée : choisir la prochaine preuve selon sa valeur pour la décision, pas seulement selon sa couverture ou son volume.

3. Les deux paris scientifiques

Pari 1 - Valeur décisionnelle de la preuve

À budget de preuve égal, une politique qui choisit la prochaine preuve selon sa valeur attendue pour la décision finale devrait produire une perte de décision plus faible que des plans fixes, aléatoires ou fondés seulement sur l'entropie.

Pari 2 - Modélisation de la qualité des preuves

Représenter explicitement la qualité du dispositif de preuve, en plus du risque du système, devrait améliorer la calibration des probabilités et, idéalement, la décision finale lorsque les preuves sont dégradées ou le modèle est mal spécifié.

Important : ces deux propositions ont été traitées comme des hypothèses falsifiables, pas comme des vérités à illustrer. Le protocole a donc été construit pour pouvoir conclure honnêtement : « cela ne fonctionne pas dans ce benchmark ».

4. Ce que la méthode ferait dans un projet réel

1. Représenter les risques latents du produit et la confiance dans le dispositif de preuve.
2. Lister les actions possibles : test, revue d'architecture, simulation, vérification d'environnement, observation terrain, etc.
3. Associer à chaque action un coût, un délai, une fiabilité et un effet attendu sur l'incertitude.
4. Mettre à jour la croyance après chaque observation.
5. Choisir soit une nouvelle preuve, soit une décision terminale : GO, CONDITIONAL GO ou NO-GO.
6. Conserver la trace complète : information d'entrée, modèle, règle, preuve acquise, mise à jour et décision.

Lien direct avec STRAT-Q

STRAT-Q cherche à transformer des exigences, risques, tests, traces et observations en une décision gouvernée. ED-POMDP est une tentative de formaliser la partie « quelle preuve demander ensuite, et quand arrêter de chercher pour décider ? ».

5. Comment on a tenté de falsifier les paris

Le principe de validation était volontairement strict : figer le protocole avant de voir les résultats, puis exécuter exactement ce qui avait été annoncé.

Dimension	Valeur figée
Politiques comparées	7
Régimes	4 : identifiable, preuve dégradée, vraisemblance mal spécifiée, non-identifiable
Budgets de preuve	2, 4, 8 et 12 acquisitions
Seeds communes	30
Épisodes bruts	3 360
Contrastes confirmatoires	240
Endpoints confirmatoires	decision loss, Brier score, ECE
Endpoint sécurité	unsafe GO, reporté mais hors famille de p-values

Pourquoi figer ? Sans gel préalable, on peut changer les seuils, choisir les seeds favorables, supprimer les régimes défavorables ou multiplier les analyses jusqu'à obtenir un résultat « significatif ». Le gel cryptographique, les comptes attendus et la correction de Holm empêchent ce glissement.

6. Les résultats, sans jargon inutile

Résultat confirmatoire

Sur 240 comparaisons prévues, une seule survit à la correction de Holm : une amélioration d'ECE face au POMDP classique, dans le régime de preuve dégradée avec un budget de 2. Le signal reste fragile : l'intervalle bootstrap traverse zéro et la cellule contient peu de probabilités finales (posteriors) distinctes.

Sur la décision finale

- Aucun contraste de decision loss ne survit à la correction multiple.
- Sur les 64 cellules directement liées au pari VOI : 10 sont favorables, 16 défavorables et 38 exactement égales.
- Le pari large « la sélection intelligente de preuve donne de meilleures décisions » n'est donc pas soutenu dans ce benchmark.

Sur la qualité probabiliste

- La direction est plus souvent favorable à ED-POMDP pour le Brier score et l'ECE.
- Mais une meilleure probabilité ne devient utile que si elle change la décision au bon moment.

Le diagnostic mécanistique le plus important

94,19 % des améliorations de Brier ne changent pas la décision

ED-POMDP obtient un meilleur Brier score dans 1 119 paires d'épisodes. Dans 1 054 de ces 1 119 cas, la décision terminale reste identique. Le système « pense » souvent un peu mieux, mais reste dans la même zone GO, CONDITIONAL GO ou NO-GO.

Exemple risk-only. ED-POMDP et la politique risk-only choisissent exactement la même décision dans 480 épisodes sur 480. Pourtant, leurs traces d'acquisition ne sont identiques que dans 205 cas et leurs probabilités finales diffèrent en moyenne. La couche d'acquisition change donc, mais la couche de décision absorbe la différence.

Le signal sécurité

Politique	Identifiable	Preuve dégradée	Mal spécifié	Non-identifiable
ED-POMDP	0	0	0	17
POMDP classique	2	2	2	18

Lecture correcte : ED-POMDP produit moins de GO dangereux dans les régimes évitables. Ce signal est important pour une Test Authority, mais il est descriptif et n'a pas fait l'objet d'un test de supériorité confirmatoire.

7. Pourquoi la promesse ne se réalise pas encore

- **Seuils de décision :** une meilleure probabilité peut rester du même côté du seuil et ne rien changer.
- **Horizon fixe :** toutes les politiques dépensent exactement le même budget, même lorsqu'une décision pourrait déjà être prise ou qu'une preuve supplémentaire serait utile.
- **Fonction de perte asymétrique :** quelques erreurs de sécurité très coûteuses peuvent dominer de nombreux petits gains.
- La qualité de preuve influence la croyance, mais la règle terminale n'utilise pas encore explicitement cette qualité comme dimension de décision.
- Le benchmark est synthétique et simplifié : petits états latents, coût unitaire et canaux de preuve peu nombreux.

8. Ce que Step 2 invalide - et ce qu'il n'invalide pas

Ce qui est invalide dans ce benchmark

La forme large de CLM-VOI-001 : rien ne montre que la politique de valeur de l'information réduit généralement la perte de décision à budget égal. La forme large de CLM-EQ-001 n'est pas soutenue non plus : le signal de calibration est trop étroit pour établir un bénéfice général.

Ce qui n'est pas invalide

La distinction conceptuelle entre risque du système et qualité des preuves reste pertinente. Le signal sécurité reste intéressant. La possibilité qu'une autre architecture de décision, un arrêt adaptatif ou des cas industriels plus riches transforme la meilleure calibration en meilleure action reste ouverte.

9. Ce que Step 2 a vraiment appris : mieux croire n'est pas encore mieux décider

Le résultat négatif n'est pas un échec de la démarche. Le protocole a rempli son rôle : il a empêché de transformer une intuition séduisante en affirmation non prouvée. Surtout, il a isolé une différence qu'il faut conserver dans la conception future : **améliorer une probabilité n'est pas la même chose qu'améliorer une décision.**

9.1 Deux qualités différentes

Notion	Question posée	Mesure dans Step 2
Qualité probabiliste	La probabilité annoncée représente-t-elle correctement la fréquence réelle du risque ? Est-elle proche de la vérité dans chaque épisode ?	Brier score et Expected Calibration Error (ECE)
Qualité de décision	L'action choisie produit-elle de bonnes conséquences compte tenu de l'état réel, des coûts et des interdictions ?	Perte de décision, GO dangereux, NO-GO inutile

Qualité probabiliste. Le modèle produit une probabilité finale $p = P(S = \text{mauvais} \mid h)$. Pour un épisode dont la vérité est $y \in \{0, 1\}$, le Brier score est :

$$B = (p - y)^2.$$

Une valeur faible signifie que la probabilité est proche de la vérité observée. L'ECE pose une autre question : lorsque le modèle annonce environ 20 % de risque sur un ensemble de cas comparables, l'événement se produit-il réellement environ 20 % du temps ? Une bonne probabilité peut donc être précise épisode par épisode, bien calibrée sur un ensemble, ou idéalement les deux.

Qualité de décision. Une probabilité n'est pas encore une action. Elle est injectée dans une règle qui compare les pertes attendues de GO, CONDITIONAL GO et NO-GO. La qualité de décision dépend alors de quatre éléments : la probabilité, les seuils qu'elle traverse, les coûts attribués aux erreurs et l'état réel finalement révélé.

Il faut distinguer deux lectures :

- **ex ante** : avec ce que l'on croyait au moment de décider, l'action minimisait-elle la perte attendue ?
- **ex post** : lorsque la vérité devient connue, quelle perte l'action a-t-elle réellement produite ?

9.2 Pourquoi une meilleure probabilité peut ne rien changer

Dans Step 2, les poids de perte figés créent deux frontières de décision :

$$p_{GO \rightarrow \text{CONDITIONAL}} = \frac{1}{13} \approx 0,077, \quad p_{\text{CONDITIONAL} \rightarrow \text{NO-GO}} = \frac{3}{11} \approx 0,273.$$

Toutes les probabilités situées entre environ 7,7 % et 27,3 % conduisent donc à CONDITIONAL GO. À l'intérieur de cette zone, le modèle peut devenir beaucoup plus juste sans que l'action change.

Exemple pédagogique : croyance améliorée, décision identique

Supposons que le système soit finalement sain, donc $y = 0$. Deux modèles annoncent respectivement $p_A = 0,18$ et $p_B = 0,24$.

$$B_A = (0,18 - 0)^2 = 0,0324, \quad B_B = (0,24 - 0)^2 = 0,0576.$$

Le modèle A est probabilistiquement meilleur. Pourtant, 0,18 et 0,24 se trouvent dans la même zone : les deux produisent CONDITIONAL GO. La qualité probabiliste s'améliore, mais la qualité de décision reste identique dans cet épisode.

C'est précisément le mécanisme observé dans le benchmark : ED-POMDP améliore le Brier dans 1 119 comparaisons, mais 1 054 de ces améliorations, soit 94,19 %, conservent la même action. Face à la politique **risk_only**, les 480 décisions sont identiques alors que les traces de preuves et les probabilités finales diffèrent souvent.

9.3 Une petite variation peut au contraire changer beaucoup

Une probabilité passant de 0,26 à 0,28 varie de seulement deux points. Pourtant, elle traverse la frontière $3/11 \approx 0,273$: CONDITIONAL GO devient NO-GO.

La valeur de ce changement dépend de la vérité :

- si le système est réellement mauvais, le NO-GO peut éviter une perte grave ;
- s'il est réellement bon, le même NO-GO peut créer un arrêt inutile ;
- la variation probabiliste n'est donc ni bonne ni mauvaise en elle-même : elle devient utile à travers la fonction de perte et le contexte réel.

Deux enseignements en découlent. Premièrement, une amélioration moyenne du Brier peut être décisionnellement inerte si elle se produit loin des seuils. Deuxièmement, quelques changements proches des seuils peuvent dominer le bilan économique ou de sécurité, surtout lorsque les pertes sont asymétriques.

9.4 Capitaliser sur un changement de prior

Le prior est la probabilité de risque utilisée *avant* la nouvelle observation. Le changer n'est pas une retouche cosmétique : il déplace tous les posteriors et peut faire traverser une frontière de décision au même résultat de test.

La relation en cotes probabilistes (odds) s'écrit :

$$\underbrace{\frac{p_{\text{apres}}}{1 - p_{\text{apres}}}}_{\text{odds apres}} = \underbrace{\frac{p_{\text{avant}}}{1 - p_{\text{avant}}}}_{\text{odds avant}} \times \underbrace{LR(o)}_{\text{rapport de vraisemblance de l'observation}}.$$

Exemple : même preuve, décision différente après révision du prior

Prenons une observation dont le rapport de vraisemblance en faveur d'un système mauvais vaut 3.

Avec un prior de 10 % :

$$\text{odds avant} = \frac{0,10}{0,90} = 0,111, \quad \text{odds apres} = 0,333, \quad p_{\text{apres}} = 0,25.$$

La décision reste CONDITIONAL GO.

Après révision du prior à 20 %, par exemple à la suite d'un nouvel historique d'incidents :

$$\text{odds avant} = \frac{0,20}{0,80} = 0,25, \quad \text{odds apres} = 0,75, \quad p_{\text{apres}} \approx 0,429.$$

La même observation conduit désormais à NO-GO. Le changement d'action vient ici du prior révisé, pas d'un test différent.

Cet exemple est pédagogique : Step 2 a conservé un prior système marginal fixé à 0,5 et n'a pas testé la sensibilité à différents priors industriels. Mais il donne une règle de capitalisation essentielle : **chaque changement de prior doit être gouverné comme un changement de modèle susceptible de modifier les décisions.**

Élément à enregistrer	Question de gouvernance
Prior précédent et nouveau prior	Quelle probabilité initiale a changé, de combien et pour quel périmètre ?
Source du changement	Incidents, production, audit, expertise, modification d'architecture ou simple jugement ?
Qualité et période des données	Les données sont-elles accessibles, représentatives, suffisamment nombreuses et encore pertinentes ?
Effet sur les posteriors	Le même résultat de test conduit-il à une probabilité sensiblement différente ?
Effet sur les seuils	Des cas passent-ils de GO à CONDITIONAL GO ou de CONDITIONAL GO à NO-GO ?
Effet observé ultérieurement	Après révélation de la vérité, la révision a-t-elle amélioré calibration, sécurité et coût de décision ?

9.5 La formulation correcte de l'apprentissage

Step 2 n'a pas appris que la qualité probabiliste serait inutile. Il a appris qu'elle est **nécessaire mais non suffisante**. Entre une bonne probabilité et une bonne décision se trouvent encore :

probabilité → seuils et pertes → action autorisée → conséquence réelle.

Le programme change donc de priorité. Il ne suffit plus d'améliorer séparément l'estimation de $P(S | h)$. Il faut étudier le **couplage complet** entre :

- la provenance et la révision du prior ;
- le pouvoir discriminant des preuves ;
- la calibration du posterior ;

- la position par rapport aux seuils ;
- les pertes non compensatoires ;
- l'arrêt, l'escalade et les contrôles compensatoires ;
- la vérification ultérieure des conséquences réelles.

Principe à retenir pour STRAT-Q

Une Quality Intelligence n'a de valeur que si une amélioration de la connaissance se convertit, au bon moment, en une action différente et meilleure. Il faut donc gouverner ensemble le prior, l'acquisition de preuve, la mise à jour de croyance, les seuils, les pertes, les contraintes, l'arrêt et l'autorité de décision.

10. La suite logique

7. Ne pas retoucher Step 2 ni réutiliser ses seeds comme preuve confirmatoire.
8. Explorer une règle terminale conditionnée à la fois par le risque système et par la qualité de preuve.
9. Introduire l'arrêt adaptatif : continuer seulement si une preuve supplémentaire peut raisonnablement changer la décision.
10. Modéliser des coûts de tests différents, des preuves redondantes ou corrélées et des contrôles compensatoires pour CONDITIONAL GO.
11. Construire des scénarios de release STRAT-Q plus réalistes et gouvernés.
12. Séparer explicitement quatre couches : observation, estimateur de croyance, résumé ponctuel éventuel et politique de décision.
13. Comparer d'abord une optimisation explicite model-based à des variantes apprises, avant d'envisager une politique RL entièrement model-free.
14. Préenregistrer ensuite un nouveau test avec de nouvelles seeds de développement et de nouvelles seeds confirmatoires intactes.

11. Comment lire les documents du programme

Document	Rôle	Quand le lire
Ce guide français	Compréhension de l'objectif, de l'intuition et de la démarche	En premier
paper/main.tex	Fondations formelles et programme de recherche - source LaTeX compilable	Pour le modèle scientifique
benchmark/results/STEP_2_7_EXECUTIVE_STATUS_NOTE.tex	État exécutif après l'expérimentation - source LaTeX compilable	Pour une synthèse courte en anglais
paper/step2_closeout.pdf	Conclusion scientifique, adjudication et mécanisme	Après avoir compris le cadre
docs/CLAIMS.*	Statut canonique des claims	Pour l'audit épistémique

12. Cinq questions pour vérifier que l'on a compris

Quel problème cherchait-on à résoudre ? Distinguer le risque réel du produit de la faiblesse éventuelle du dispositif de preuve.

Quelle était l'intuition ? Choisir la prochaine preuve selon sa valeur pour la décision, tout en modélisant explicitement la qualité des preuves.

Comment a-t-on évité de bricoler les résultats ? En figeant avant exécution les seeds, budgets, politiques, endpoints, pertes, analyses et correction de multiplicité.

Qu'a montré Step 2 ? Une meilleure calibration fréquente, mais très rarement convertie en changement de décision ; aucun gain général de decision loss confirmé.

Que faut-il maintenant revoir ? Le couplage entre observation, estimateur de croyance, qualité de preuve, seuils, arrêt adaptatif, optimisation, contraintes et action terminale.

Conclusion en langage direct

En clair

Nous avons testé si une méthode plus intelligente pour choisir les preuves et représenter leur qualité conduisait à de meilleures décisions de release. Elle produit souvent de meilleures probabilités et un signal sécurité intéressant, mais elle ne produit pas de meilleures décisions de façon générale dans le benchmark figé. La prochaine avancée ne consiste donc pas à ajouter davantage de simulation, mais à construire proprement la chaîne observation → croyance → optimisation → action, puis à vérifier si une politique explicite ou apprise convertit réellement une meilleure connaissance en meilleure décision.

Annexe A — Chapitre d'étude : contester le POMDP de sélection des tests

Idée centrale

On ne choisit pas nécessairement le test qui trouve le plus de défauts. On choisit le test dont le résultat devrait le plus améliorer la décision finale, compte tenu de son coût.

Le problème combine trois éléments :

1. notre incertitude actuelle sur le système ;
2. la capacité d'un test à réduire cette incertitude ;
3. l'utilité réelle de cette information pour décider entre **GO**, **CONDITIONAL GO**, **NO-GO** ou **ESCALATE**.

A.0 Le modèle minimal du chapitre

Le modèle définit :

- S : l'état latent, c'est-à-dire l'état réel du risque ;
- $b(s)$: notre croyance actuelle sur cet état ;
- a : une action, par exemple exécuter un test ;
- o : l'observation obtenue ;
- $C(a)$: le coût de l'action ;
- la récompense : la réduction du risque décisionnel, moins le coût.

Lecture en français

$$b(s)$$

se lit « bé de esse » et signifie : « la probabilité que l'état réel soit s , compte tenu de tout ce que nous savons actuellement ».

Attention : b ne désigne pas l'état réel. Il représente **ce que nous croyons sur cet état**.

A.1 L'état réel du risque est-il une variable unique ?

Le modèle peut représenter :

$$S = (S_{\text{fonctionnel}}, S_{\text{sécurité}}, S_{\text{performance}}, S_{\text{opérationnel}}, S_{\text{contractuel}}).$$

Lecture en français. « L'état S est un vecteur composé du risque fonctionnel, du risque de sécurité, du risque de performance, du risque opérationnel et du risque contractuel. » Plus simplement : « L'état réel du système possède cinq dimensions de risque. » Les parenthèses n'indiquent pas une addition, mais un **vecteur**, c'est-à-dire un ensemble ordonné de composantes.

Niveau intuition. Réduire tout le risque à une note unique, par exemple 72/100, peut être trompeur. Deux systèmes peuvent avoir la même note moyenne : le premier possède un petit défaut fonctionnel sans conséquence majeure ; le second une vulnérabilité de sécurité rare mais catastrophique. La moyenne peut être identique, mais la décision ne devrait pas l'être. Le vecteur conserve la structure du risque avant la décision.

Niveau rigueur. S est une variable aléatoire multidimensionnelle. Une réalisation possible serait :

$$s = (0.1, 0.8, 0.2, 0.3, 0.1),$$

où chaque nombre représente un niveau de risque dans une dimension. La croyance complète est une distribution jointe :

$$b(s) = P(S = s \mid h),$$

où h représente l'historique disponible : tests antérieurs, traces OTEL, revues, défauts connus, configuration de l'environnement, etc.

Il ne suffit pas nécessairement de conserver cinq probabilités indépendantes. Un défaut de sécurité peut dégrader la performance ; une mauvaise configuration opérationnelle peut provoquer des échecs fonctionnels ; un défaut contractuel peut dépendre d'un seuil de performance. Les composantes peuvent donc être corrélées.

Niveau hybride : relier le vecteur à la décision. On conserve le risque sous forme vectorielle, mais on finit par choisir une décision d . Introduisons une fonction de perte :

$$L(d, s),$$

qui se lit : « la perte associée à la décision d , lorsque l'état réel est s ». Autoriser un GO dans un état comportant un risque de sécurité critique peut avoir une perte très élevée. Le risque décisionnel actuel s'écrit :

$$R(b) = \min_d \mathbb{E}_{s \sim b}[L(d, s)].$$

Lecture de la formule

« Le risque associé à la croyance b est la plus petite perte moyenne que nous puissions obtenir en choisissant la meilleure décision disponible. » Le symbole $\min_d$ signifie que l'on compare toutes les décisions possibles et que l'on conserve celle donnant la plus faible perte attendue. La scalarisation intervient donc au moment de décider, et non prématurément dans la représentation de l'état.

A.2 Une absence de défaut est-elle une observation ?

Le modèle écrit :

$$P(S \mid \text{PASS}) \propto P(\text{PASS} \mid S)P(S).$$

Lecture littérale.

- $P(S \mid \text{PASS})$: « la probabilité de l'état S , sachant que le test a donné PASS » ;
- $\propto$: « est proportionnelle à » ;
- $P(\text{PASS} \mid S)$: « la probabilité que le test donne PASS, si l'état réel est S » ;
- $P(S)$: « la probabilité préalable de l'état S ».

La formule se lit donc : « La probabilité de l'état du système sachant que le test a réussi est proportionnelle à la probabilité que le test réussisse dans cet état, multipliée par la probabilité que nous attribuions auparavant à cet état. »

Niveau intuition. Un test qui passe ne démontre pas nécessairement que le système est sain. Il faut demander : « Ce test aurait-il également passé si le système était défaillant ? » Si oui, le PASS apporte peu d'information.

Exemple. Un test vérifie uniquement que l'API répond HTTP 200. Il peut passer lorsque le système est correct, mais aussi lorsque les données retournées sont fausses, que l'autorisation est contournée ou que le traitement asynchrone échoue après la réponse. Le PASS est une observation réelle, mais peu discriminante.

Niveau rigueur : formule de Bayes complète. Pour une valeur particulière s :

$$P(S = s \mid \text{PASS}) = \frac{P(\text{PASS} \mid S = s)P(S = s)}{P(\text{PASS})}.$$

Le symbole $\propto$ omet le dénominateur commun $P(\text{PASS})$, qui normalise les probabilités. Dans un espace discret :

$$P(\text{PASS}) = \sum_s P(\text{PASS} \mid S = s)P(S = s).$$

Niveau hybride : pouvoir discriminant. Supposons deux hypothèses : H_0 , le système est sain, et H_1 , le système est défaillant. Après un PASS :

$$\frac{P(H_0 \mid \text{PASS})}{P(H_1 \mid \text{PASS})} = \frac{P(\text{PASS} \mid H_0)}{P(\text{PASS} \mid H_1)} \times \frac{P(H_0)}{P(H_1)}.$$

Le premier rapport est le **rapport de vraisemblance** du PASS. Si

$$P(\text{PASS} \mid H_0) = 0.99 \quad \text{et} \quad P(\text{PASS} \mid H_1) = 0.95,$$

alors :

$$\frac{0.99}{0.95} \approx 1.04.$$

Le PASS ne favorise l'hypothèse « système sain » que d'un facteur 1.04, ce qui est très faible. Si, au contraire,

$$P(\text{PASS} \mid H_1) = 0.10,$$

alors le rapport vaut 9.9 : le PASS devient beaucoup plus informatif.

Conclusion de A.2

Ce n'est pas le mot PASS qui constitue une preuve absolue. La valeur de la preuve vient de la différence entre la probabilité d'obtenir PASS dans les différents états possibles.

A.3 Le test le plus susceptible de trouver un défaut est-il le meilleur ?

La réponse est **non**. Introduisons :

$$\text{EVI}_{\text{nette}}(a) = R(b) - \mathbb{E}_o[R(b^{a,o})] - C(a).$$

Lecture complète. « La valeur espérée nette de l'information apportée par l'action a est égale au risque décisionnel actuel $R(b)$, moins le risque décisionnel moyen attendu après avoir exécuté l'action a et observé son résultat o , moins le coût de l'action $C(a)$. » EVI signifie *Expected Value of Information*, soit « valeur espérée de l'information ».

Lecture symbole par symbole.

- a : l'action, par exemple un test de charge, une revue de sécurité, une comparaison d'environnements, l'inspection d'une trace OTEL ou une campagne terrain ;
- o : l'observation, par exemple PASS, FAIL, latence excessive, absence de trace, erreur spécifique ou résultat ambigu ;
- $b^{a,o}$: « bé après l'action a et l'observation o » ; ce n'est pas une puissance, mais la croyance mise à jour ;
- $\mathbb{E}_o$: l'espérance sur toutes les observations possibles, pondérées par leurs probabilités ;
- $C(a)$: le coût en temps, infrastructure, mobilisation d'experts, calendrier, données, environnement ou risque introduit par le test.

Si un test ne peut produire que PASS et FAIL :

$$\mathbb{E}_o[R(b^{a,o})] = P(\text{PASS} \mid b, a)R(b^{a,\text{PASS}}) + P(\text{FAIL} \mid b, a)R(b^{a,\text{FAIL}}).$$

Niveau intuition. Un test est utile lorsqu'il peut modifier notre décision. Un test qui trouve souvent des défauts mineurs peut être moins utile qu'un test rare mais capable de distinguer GO de NO-GO. La bonne question n'est pas « Quel test trouvera probablement un défaut ? », mais « Quel test devrait le plus réduire le coût de notre future décision ? »

Niveau rigueur. La quantité

$$R(b) - \mathbb{E}_o[R(b^{a,o})]$$

est la valeur brute de l'information. Après soustraction de $C(a)$, la règle devient :

$$\text{EVI}_{\text{nette}}(a) > 0 \implies \text{l'action peut être rationnelle selon le modèle.}$$

Si $\text{EVI}_{\text{nette}}(a) \leq 0$, le test coûte au moins autant que la réduction attendue du risque décisionnel.

Exemple chiffré. Supposons :

$$R(b) = 20, \quad C(a) = 3.$$

Le test donne PASS avec probabilité 70% et laisse un risque résiduel de 15 ; il donne FAIL avec probabilité 30% et permet une décision protectrice ramenant le risque à 5. Alors :

$$\mathbb{E}_o[R(b^{a,o})] = 0.7 \times 15 + 0.3 \times 5 = 12,$$

puis :

$$\text{EVI}_{\text{nette}}(a) = 20 - 12 - 3 = 5.$$

Le test réduit en moyenne le risque de huit unités, coûte trois unités et possède donc une valeur nette de cinq.

Le piège du double comptage

Si l'on définit déjà

$$\text{EVI}_{\text{nette}}(a) = R(b) - \mathbb{E}_o[R(b^{a,o})] - C(a),$$

le coût est soustrait. On compare donc cette quantité à zéro. La comparer ensuite à $C(a)$ pénaliserait le coût deux fois.

Deux conventions équivalentes sont possibles :

Convention brute

$$\text{EVI}_{\text{brute}}(a) = R(b) - \mathbb{E}_o[R(b^{a,o})], \quad \text{EVI}_{\text{brute}}(a) > C(a).$$

Convention nette

$$\text{EVI}_{\text{nette}}(a) = \text{EVI}_{\text{brute}}(a) - C(a), \quad \text{EVI}_{\text{nette}}(a) > 0.$$

Les deux conventions sont équivalentes si elles ne sont pas mélangées.

A.4 Cas limites

1. Observation parfaite. Si l'état pertinent est réellement observable au moment de décider, le POMDP se réduit à un MDP. La croyance devient concentrée sur un seul état :

$$b(s) = \begin{cases} 1 & \text{pour l'état observé,} \\ 0 & \text{pour les autres états.} \end{cases}$$

La décision dépend directement de s plutôt que de b .

2. Observation non informative. Si

$$P(o \mid s_1) = P(o \mid s_2),$$

le test ne distingue pas les deux états. La mise à jour donne

$$b'(s) \propto P(o \mid s)b(s).$$

Si $P(o | s) = k$ pour tous les états, alors après normalisation :

$$b'(s) = b(s).$$

La croyance ne change pas. Il faut alors changer de test, améliorer l'oracle, ajouter une sonde, modifier l'instrumentation, intervenir sur l'environnement ou reconnaître que le risque n'est pas identifiable avec les observations disponibles.

3. Risque déjà nul ou décision dominée. Une information n'a de valeur décisionnelle que si elle peut modifier l'action ou réduire sa perte. Si une règle contractuelle impose déjà NO-GO parce qu'un certificat obligatoire manque, un excellent test de performance peut être techniquement utile mais ne changera pas la décision immédiate. Si

$$R(b) = \mathbb{E}_o[R(b^{a,o})],$$

alors $\text{EVI}_{\text{brute}}(a) = 0$ et, puisque $C(a) \geq 0$, $\text{EVI}_{\text{nette}}(a) \leq 0$.

4. Autorité dépassée. La meilleure action peut être ESCALATE. Le modèle ne doit pas inventer une décision lorsqu'il manque l'autorité, l'information, la compétence, les critères éthiques ou la légitimité contractuelle. ESCALATE peut être une action véritable, avec un coût, un délai, une probabilité d'obtenir une expertise supplémentaire et une réduction attendue du risque. On pourrait comparer :

$$\text{EVI}_{\text{nette}}(\text{test}) \quad \text{et} \quad \text{EVI}_{\text{nette}}(\text{ESCALATE}).$$

A.5 Ce qu'il faut retenir

1. L'état du risque est potentiellement multidimensionnel : $S = (S_1, \dots, S_n)$. Il ne faut pas agréger trop tôt des risques non compensatoires.
2. Un PASS est une observation, pas une preuve absolue. Sa valeur dépend de la sensibilité et du pouvoir discriminant du test.
3. Le meilleur test est celui qui améliore le plus la décision nette de son coût, pas nécessairement celui qui maximise le nombre de défauts détectés.
4. Il faut savoir s'arrêter lorsque

$$\max_a \text{EVI}_{\text{nette}}(a) \leq 0.$$

Autrement dit, aucune preuve supplémentaire disponible ne devrait améliorer suffisamment la décision pour justifier son coût.

A.6 Mini-révision

1. Dans $P(S | \text{PASS})$, que signifie exactement la barre verticale ?
2. Pourquoi un test qui passe dans 99% des systèmes sains et dans 98% des systèmes défaillants apporte-t-il peu d'information ?
3. Dans $b^{a,o}$, l'exposant représente-t-il une puissance ?
4. Calculez la valeur nette lorsque

$$R(b) = 14, \quad \mathbb{E}_o[R(b^{a,o})] = 9, \quad C(a) = 3.$$

5. Un test peut-il avoir une excellente capacité de détection mais une valeur décisionnelle presque nulle ? Donnez un exemple dans un contexte de test et d'intégration.

Annexe B — De MDP à POMDP puis ED-POMDP : genèse, vocabulaire et applications

Pourquoi cette annexe ?

ED-POMDP n'est pas un sigle isolé. Il s'inscrit dans une histoire de la décision séquentielle sous incertitude : d'abord décider dans un état observable, puis décider lorsque cet état est caché, enfin distinguer explicitement l'état du système de la qualité du dispositif qui produit les preuves.

B.1 Avant le MDP : décision séquentielle et principe d'optimalité

Une décision de projet n'est pas toujours un choix unique. Une action modifie la situation, produit de nouvelles informations et change les choix futurs. La programmation dynamique, associée notamment à Richard Bellman dans les années 1950, formalise le principe suivant : une politique optimale doit rester optimale à partir de tout état intermédiaire atteint.

Un **processus de décision markovien**, ou MDP, suppose que l'état courant contient toute l'information pertinente pour prédire l'avenir compte tenu de l'action. « Markovien » ne signifie pas que le passé n'existe pas ; cela signifie que son influence utile a été résumée dans l'état courant.

B.2 Le MDP en français dans le texte

Un MDP discret s'écrit souvent :

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, T, R, \gamma).$$

Il comprend :

- $\mathcal{S}$: l'ensemble des états observables ;
- $\mathcal{A}$: l'ensemble des actions ;
- $T(s' | s, a)$: la probabilité de passer de s à s' après l'action a ;
- $R(s, a)$, ou une fonction de coût équivalente : la valeur immédiate de l'action ;
- γ : le facteur d'actualisation, qui pondère les conséquences futures.

La politique $\pi(a | s)$ indique quelle action choisir dans chaque état. La fonction de valeur répond à la question : « Quelle valeur totale puis-je espérer si je pars de cet état et que j'applique cette politique ? »

Exemples historiques et industriels. Maintenance d'une machine, remplacement d'un équipement, gestion de stock, ordonnancement, contrôle d'un véhicule, planification de capacité ou politique de réparation. Le livre de Puterman rassemble cette formulation et de nombreux exemples de décision séquentielle.

B.3 Pourquoi le MDP ne suffit plus lorsque l'état est caché

Dans un projet réel, le décideur ne voit pas directement « l'état véritable du risque ». Il observe des tests, des logs, des métriques, des audits et des symptômes. Deux états internes différents peuvent produire la même observation. Le problème devient partiellement observable.

Un POMDP ajoute donc un espace d'observations et un modèle d'observation :

$$\mathcal{P} = (\mathcal{S}, \mathcal{A}, T, \mathcal{O}, Z, R, \gamma).$$

Ici :

- $\mathcal{O}$ est l'ensemble des observations ;
- $Z(o | s', a)$ est la probabilité d'observer o après l'action a lorsque le nouvel état est s' .

Comme l'état n'est pas directement connu, le décideur entretient une **croyance** :

$$b_t(s) = P(S_t = s | h_t),$$

où h_t est l'historique des actions et observations. Cette croyance est un état d'information pleinement observable : le POMDP peut ainsi être reformulé comme un MDP sur l'espace des croyances.

Après une action a et une observation o , la mise à jour s'écrit, à normalisation près :

$$b'(s') \propto Z(o | s', a) \sum_s T(s' | s, a) b(s).$$

Lecture : on prédit d'abord le prochain état avec le modèle de transition, puis on corrige cette prédiction selon la vraisemblance de l'observation reçue.

B.4 Chronologie condensée du POMDP

Date	Référence	Apport
1957	Richard Bellman	Formulation classique d'un processus de décision markovien et programmation dynamique.
1965	Karl J. Åström	Contrôle optimal de processus de Markov lorsque l'état est incomplet ou indirectement observé.
1971	Edward J. Sondik	Thèse de Stanford sur le contrôle optimal des processus partiellement observables.
1973	Smallwood et Sondik	Résultat de structure à horizon fini : fonction de valeur linéaire par morceaux et convexe sur l'espace des croyances, avec exemple de maintenance.
1978	Sondik	Extension à l'horizon infini avec coûts actualisés et politiques stationnaires approchées.
1998	Kaelbling, Littman et Cassandra	Passage vers la communauté IA : planifier et agir dans des domaines stochastiques partiellement observables.
Aujourd'hui	Contrôle, IA et aide à la décision	Robotique, véhicules autonomes, maintenance, médecine, interaction, surveillance, exploration et systèmes d'aide à la décision.

Le cours Stanford AA228/CS238 présente aujourd'hui cette continuité : modèles probabilistes, théorie de la décision, programmation dynamique, apprentissage par renforcement et POMDP, avec des applications en contrôle aérien, surveillance aéronautique, véhicules autonomes et exploration robotique.

B.5 Applications typiques du POMDP

- **Maintenance** : l'état interne d'une machine est caché ; inspections et capteurs sont imparfaits ; il faut décider d'observer, réparer ou continuer.
- **Robotique et navigation** : la position ou l'état du monde sont incertains ; les capteurs sont bruités ; les actions modifient l'environnement.
- **Médecine** : l'état clinique est latent ; examens et symptômes sont imparfaits ; il faut choisir entre observer, traiter ou attendre.
- **Dialogue et assistance** : l'intention de l'utilisateur est cachée ; chaque question fournit une observation ; le système choisit entre répondre, préciser ou transférer.
- **Inspection et sûreté** : défauts, menaces et dégradations ne sont pas directement visibles ; les campagnes d'inspection ont des coûts et sensibilités différents.
- **Décision de release** : le niveau réel de risque est latent ; les tests et traces sont des observations ; les décisions terminales sont GO, CONDITIONAL GO, NO-GO ou ESCALATE.

B.6 La genèse d'ED-POMDP

La réflexion initiale sur la gouvernance de qualité disposait déjà de plusieurs éléments : registre de risques, couverture des exigences, campagnes de tests, traces d'observabilité, maturité des environnements, décision GO/NO-GO, coût et calendrier. Ces éléments décrivaient assez bien *ce que l'on savait*, mais ils ne répondaient pas complètement à deux questions dynamiques :

1. quelle preuve faut-il demander ensuite ?
2. à quel moment faut-il arrêter d'acquérir des preuves et décider ?

Une première évolution consiste à représenter le risque comme une croyance bayésienne et les tests comme des actions d'acquisition d'information. Cela conduit naturellement au POMDP. Mais une difficulté supplémentaire apparaît : le résultat d'un test dépend non seulement de l'état du système, mais aussi de la qualité du dispositif qui produit la preuve.

Un PASS obtenu sur une version incorrecte, dans un environnement peu représentatif, avec un oracle incomplet ou un mock trop favorable n'a pas la même signification qu'un PASS produit par une campagne fraîche, traçable et représentative. La qualité de la preuve est elle-même partiellement cachée.

ED-POMDP introduit donc deux familles de variables latentes :

$$S_t = \text{état réel du système}, \quad E_t = \text{état de production et de qualité des preuves}.$$

La croyance devient :

$$b_t(s, e) = P(S_t = s, E_t = e \mid h_t).$$

Les actions ne sont plus uniquement des tests fonctionnels. Elles peuvent inclure :

- un test ciblé ou une campagne ;
- une revue d'architecture ou de code ;
- une vérification d'environnement ;

- l’ajout ou la validation d’une instrumentation ;
- une comparaison inter-environnements ;
- une intervention contrôlée ;
- une décision terminale GO, CONDITIONAL GO, NO-GO ou ESCALATE.

Ce que signifie le E de ED-POMDP

Le E renvoie à une approche *Evidence-Driven* : la politique ne considère pas seulement le risque supposé du produit, mais aussi la provenance, la qualité, la représentativité et la valeur décisionnelle des preuves qu’elle choisit d’acquérir.

B.7 Ce qu’ED-POMDP ajoute — et ce qu’il n’ajoute pas automatiquement

ED-POMDP ajoute une structure conceptuelle pour distinguer :

- le système et son dispositif d’observation ;
- l’amélioration d’une probabilité et l’amélioration d’une décision ;
- la quantité de tests et la valeur de la prochaine preuve ;
- l’arrêt rationnel et l’accumulation automatique de campagnes.

Il ne garantit pas automatiquement une meilleure décision. Le benchmark Step 2 a précisément montré qu’une meilleure calibration ou un meilleur Brier score peut rester sans effet sur l’action terminale. Sous les seuils, horizons fixes et pertes gelés, 94.19% des améliorations de Brier observées n’ont pas changé la décision. La contribution actuelle est donc autant une falsification qu’une proposition de modèle.

B.8 Statut scientifique et filiation

- **MDP** et **POMDP** sont des cadres scientifiques établis, avec une littérature historique et contemporaine importante.
- **ED-POMDP** est une extension de recherche appliquée à l’assurance de release. Ce n’est pas un standard reconnu ni une supériorité industrielle démontrée.
- Son statut courant est celui d’un programme reproductible ayant clos un benchmark synthétique et borné ses claims.
- Toute généralisation industrielle exige une nouvelle prérégistration, des données gouvernées et des évaluations indépendantes.

B.9 Références canoniques et ressources officielles

- [1] R. Bellman, « A Markovian Decision Process », *Journal of Mathematics and Mechanics*, vol. 6, no 5, p. 679–684, 1957.
- [2] K. J. Åström, « Optimal Control of Markov Processes with Incomplete State Information I », *Journal of Mathematical Analysis and Applications*, vol. 10, p. 174–205, 1965. DOI : 10.1016/0022-247X(65)90154-X.
- [3] E. J. Sondik, *The Optimal Control of Partially Observable Markov Processes*, thèse de doctorat, Stanford University, 1971.
- [4] R. D. Smallwood et E. J. Sondik, « The Optimal Control of Partially Observable Markov Processes over a Finite Horizon », *Operations Research*, vol. 21, no 5, p. 1071–1088, 1973. DOI : 10.1287/opre.21.5.1071.
- [5] E. J. Sondik, « The Optimal Control of Partially Observable Markov Processes over the Infinite Horizon : Discounted Costs », *Operations Research*, vol. 26, no 2, p. 282–304, 1978. DOI : 10.1287/opre.26.2.282.
- [6] M. L. Puterman, *Markov Decision Processes : Discrete Stochastic Dynamic Programming*, Wiley, 1994. DOI : 10.1002/9780470316887.
- [7] L. P. Kaelbling, M. L. Littman et A. R. Cassandra, « Planning and Acting in Partially Observable Stochastic Domains », *Artificial Intelligence*, vol. 101, p. 99–134, 1998. DOI : 10.1016/S0004-3702(98)00023-X.
- [8] Stanford University, *AA228/CS238 — Decision Making under Uncertainty*. Site officiel : aa228.stanford.edu.

B.10 Publications du programme et liens directs

Publication	Version et date	Accès
<i>ED-POMDP Research Edition — Step 2 Benchmark Close-Out</i>	v1.3.0-step2-closeout, 1 août 2026	Dépôt : github.com/gharbonnier78/ed-pomdp . PDF direct : paper/step2_closeout.pdf .
<i>Testing Beyond Automation : Evidence, Doubt, and Operational Risk in the Age of Generative AI</i>	v1.0, Initial Proposal Draft, non évalué par les pairs ; date de publication non déclarée dans le dépôt (consulté le 1 août 2026)	Dépôt : github.com/gharbonnier78/stratq-ai . PDF direct : Whitepaper_PDF_v1_0_initial_draft.pdf .

Annexe C — Peut-on réellement chiffrer toutes les variables ?

Réponse directe

Non. Dans un projet réel, certaines variables sont observées directement, d'autres sont calculées, d'autres encore sont estimées ou négociées, et les variables les plus importantes — l'état réel du système et la qualité réelle de la preuve — restent souvent latentes. Un modèle POMDP ne supprime pas cette difficulté : il la rend explicite.

C.1 Cinq statuts différents derrière le mot « variable »

Statut	Exemples	Ce que cela implique
Observée	résultat PASS/FAIL, durée, trace OTEL, version déployée, configuration, défaut ouvert	La valeur existe dans un outil, mais elle doit être fraîche, complète, horodatée et reliée à la bonne version.
Calculée	taux de réussite, couverture, score de Brier, ECE, coût consommé, distance à un seuil	Le calcul est reproductible si la formule, les données d'entrée et le code sont versionnés.
Estimée	sensibilité d'un test, probabilité de défaillance, fiabilité d'un mock, vraisemblance $P(o s)$	Il faut des données, une expertise ou une expérience contrôlée ; l'incertitude sur l'estimation doit être conservée.
Latente	état réel du système S , qualité réelle de la preuve E	Elle n'est pas directement accessible. On ne voit que ses effets indirects.
Normative	coût d'un unsafe GO, seuil de décision, valeur d'un jour de retard, autorité d'acceptation	Ce n'est pas une vérité statistique : c'est une décision de gouvernance portée par des responsables identifiés.

Ainsi, « chiffrer » ne veut pas toujours dire « mesurer ». Le chiffre peut provenir d'une mesure, d'une formule, d'une estimation experte, d'une convention contractuelle ou d'un modèle. Ces origines ne doivent jamais être mélangées dans un même indicateur sans provenance.

C.2 Faut-il nécessairement un historique ?

Pas toujours, mais il faut toujours une base explicite pour les probabilités et les coûts.

- **Sans historique industriel**, on peut commencer avec des priors documentés, des fourchettes expertes, des données produit, des essais ciblés et des simulations. Le résultat doit alors rester qualifié d'exploratoire ou synthétique.
- **Avec un historique**, il faut encore vérifier qu'il est comparable au projet courant : même architecture, même version, mêmes environnements, mêmes populations, mêmes pratiques de test et mêmes définitions de défaut.
- **Avec un historique incomplet ou inaccessible**, le problème n'est pas seulement statistique. Il devient un problème de gouvernance des données, de droits d'accès, de confidentialité, de rétention, de qualité des labels et de traçabilité.

Le benchmark Step 2 n'utilise aucun historique de projet réel. Il génère entièrement ses épisodes à partir d'un simulateur déterministe. Cela garantit l'accessibilité et la reproductibilité, mais ne démontre pas la représentativité industrielle.

C.3 Qu'est-ce qu'un historique fiable et accessible ?

Un historique est utilisable seulement si l'on peut répondre à ces questions :

1. À quelle version du produit, de la configuration et de l'environnement chaque observation se rapporte-t-elle ?
2. Le résultat est-il associé à un oracle explicite, ou seulement à un statut « vert » ?
3. Les échecs absents signifient-ils « aucun défaut » ou « aucun défaut observé » ?
4. Les incidents de production sont-ils reliés aux tests qui auraient dû les détecter ?
5. Les changements de processus, d'outils ou de populations sont-ils enregistrés ?
6. Les données manquantes, supprimées ou inaccessibles sont-elles visibles comme telles ?
7. Les décisions GO / NO-GO et les raisons de ces décisions sont-elles conservées ?

Le piège de l'historique « propre »

Un historique ne contenant que les tests exécutés avec succès ne permet pas d'estimer la sensibilité réelle des tests. Pour apprendre $P(\text{PASS} | S = \text{mauvais})$, il faut connaître des cas où le système était effectivement mauvais, y compris des défauts découverts plus tard en production ou par une autre preuve.

C.4 Implications au niveau du processus

Un usage industriel exige au minimum :

- un **contrat de preuve** définissant résultat, oracle, version, environnement, données, horodatage et identifiant de trace ;

- un **registre des hypothèses** distinguant faits observés, estimations et conventions de coût ;
- une **boucle de retour** reliant incidents, défauts tardifs et décisions passées aux preuves qui les avaient précédés ;
- un **data-readiness gate** avant toute calibration industrielle ;
- une revue périodique de dérive : le test, l'environnement ou la population ont-ils changé ?
- une règle d'escalade lorsque les données disponibles ne permettent pas d'identifier le risque.

C.5 Implications au niveau des outils

Les outils doivent conserver les relations, pas seulement des fichiers séparés :

- exigence / risque / test / exécution / défaut / trace / décision ;
- digest de l'image, commit, configuration et environnement ;
- identifiants OTEL et horodatages corrélables ;
- version des modèles, priors, seuils et fonctions de perte ;
- provenance des données et contrôle d'accès ;
- artefacts de calibration et résultats reproductibles.

Un outil de gestion de tests peut stocker l'exécution ; une plateforme CI peut lancer le scénario ; OTEL peut fournir les signaux ; un dépôt versionné peut gouverner le modèle. Aucun outil unique ne garantit à lui seul la qualité épistémique de l'ensemble.

C.6 Implications humaines

Rôle	Responsabilité minimale
QA / Test Lead	Définir l'oracle, la sensibilité attendue, les limites du test et la provenance de l'exécution.
Tech Lead / Architecte	Valider les hypothèses causales, les dépendances, la représentativité de l'environnement et les mécanismes techniques.
Chef de projet / Produit	Rendre explicites coûts, calendrier, criticité et décisions réellement modifiables.
Métier / Sécurité / Juridique	Définir les risques non compensatoires et les limites d'autorité.
Statisticien / Data / ML	Évaluer calibration, incertitude, taille d'échantillon, dérive et validité des comparaisons.
Autorité de décision	Assumer les poids de perte, les seuils, l'acceptation du risque et l'escalade.

Annexe D — Les données synthétiques de Step 2, présentées et critiquées

Ce que signifie « synthétique » ici

Les données ne proviennent ni d'un projet, ni d'une base de défauts, ni d'un système de test réel. Elles sont générées par un modèle volontairement petit : deux variables latentes binaires, deux canaux d'observation binaires, quatre conditions expérimentales, quatre budgets et trente seeds. Elles servent à tester le raisonnement du modèle dans un monde contrôlé, pas à reproduire toute la diversité industrielle.

D.1 Les variables générées

Le simulateur contient deux états cachés :

$$S \in \{\text{bon, mauvais}\}, \quad E \in \{\text{preuve bonne, preuve dégradée}\}.$$

À chaque épisode, $P(S = \text{mauvais}) = 0.5$. Pour E , le prior vaut 0.5, sauf dans la condition « preuve dégradée », où $P(E = \text{dégradée}) = 0.8$.

Deux actions d'observation sont disponibles :

- `functional` : un test fonctionnel censé informer sur S lorsque la preuve est bonne ;
- `environment_validation` : une validation d'environnement censée informer sur E .

D.2 Les probabilités du générateur, en français

Situation	$P(\text{FAIL})$	Lecture
Test fonctionnel, système bon, preuve bonne	0.10	Un bon système échoue rarement lorsque le dispositif de preuve fonctionne.
Test fonctionnel, système mauvais, preuve bonne	0.95	Un mauvais système échoue presque toujours : le test est fortement discriminant.
Test fonctionnel, preuve dégradée	0.60	Le résultat devient presque indépendant de l'état réel du système.
Validation d'environnement, preuve bonne	0.20	L'environnement échoue rarement lorsque la preuve est fiable.
Validation d'environnement, preuve dégradée	0.80	La validation signale souvent une preuve de mauvaise qualité.

Dans la condition « modèle mal spécifié », le monde réel synthétique utilise des probabilités différentes de celles que la politique croit : 0.15/0.85/0.70 pour le canal fonctionnel et 0.30/0.70 pour la validation d'environnement. Dans la condition non identifiable, les deux canaux sont volontairement rendus incapables de séparer certaines causes latentes.

D.3 Traduction des quatre « régimes » sans jargon

Nom du code	Ce que cela veut dire en langage projet
<code>identifiable</code>	Les deux types de test fournissent ensemble assez d'information pour distinguer le risque produit de la qualité de la preuve, au moins en principe.
<code>evidence_degraded</code>	Le dispositif de preuve est beaucoup plus souvent dégradé ; les tests fonctionnels deviennent fréquemment peu fiables.
<code>likelihood_misspecified</code>	Le modèle utilisé pour interpréter les tests ne correspond pas exactement au monde qui génère les résultats.
<code>non_identifiable</code>	Des causes latentes différentes peuvent produire les mêmes observations ; aucune quantité de répétitions identiques ne permet de les séparer.

D.4 Combien de données y a-t-il réellement ?

Le fichier brut contient 3 360 lignes :

$$4 \text{ conditions} \times 4 \text{ budgets} \times 30 \text{ seeds} \times 7 \text{ politiques}.$$

Mais ces 3 360 lignes ne sont pas 3 360 projets indépendants.

- Il existe 480 unités appariées (condition, budget, seed).
- Les sept politiques voient le même scénario latent dans chaque unité : elles sont comparées par paires, elles ne constituent pas sept observations indépendantes.
- Il existe seulement 120 bandes exogènes distinctes ($4 \text{ conditions} \times 30 \text{ seeds}$), réutilisées pour les quatre budgets.
- Chaque cellule de métrique contient 30 seeds.
- Les budgets sont imbriqués : un budget 4 réutilise les deux premières observations du budget 2 pour une même seed.

Conséquence statistique

Le volume de lignes est suffisant pour un benchmark contrôlé et apparié, mais il ne faut pas le confondre avec un historique industriel de milliers de releases indépendantes. La taille d'échantillon pertinente pour une cellule confirmatoire reste trente.

D.5 Les états latents effectivement tirés

La figure suivante compte les trente seeds uniques de chaque condition, sans répéter artificiellement les sept politiques ni les quatre budgets.




FIGURE 1 – Répartition des quatre combinaisons (S, E) réellement générées par condition. La condition « preuve dégradée » concentre davantage de seeds avec E dégradée, conformément au prior fixé à 0.8.

D.6 Les distributions ne sont pas gaussiennes

Les probabilités finales sont produites par des suites courtes d'observations binaires. Elles prennent donc un nombre limité de valeurs et forment des pics. Il n'existe aucune raison de les supposer normales.




FIGURE 2 – Distribution des probabilités finales pour ED-POMDP et le POMDP classique. Les seuils verticaux transforment ensuite ces probabilités en décisions.

Le score de Brier n'est pas non plus une variable gaussienne : il vaut $(p - y)^2$, avec $y \in \{0, 1\}$. Sa forme dépend directement de la vérité latente et de la probabilité prédite.




FIGURE 3 – Relation déterministe entre probabilité finale, vérité latente et score de Brier pour les 480 épisodes ED-POMDP.

C'est notamment pour éviter une hypothèse de normalité fragile que Step 2 utilise un bootstrap apparié et un test de permutation, puis une correction de Holm sur la famille confirmatoire.

D.7 Comment la probabilité devient une décision

Avec les pertes gelées, les frontières sont :

$$p_{GO/COND} = \frac{1}{13} \approx 0.0769, \quad p_{COND/NO} = \frac{3}{11} \approx 0.2727.$$

Ainsi :

- si $p < 0.0769$, la décision optimale est GO ;
- si $0.0769 \leq p < 0.2727$, elle est CONDITIONAL GO ;
- si $p \geq 0.2727$, elle est NO-GO.




FIGURE 4 – Les probabilités peuvent varier sans franchir une frontière de décision. C'est le mécanisme central de l'inertie décisionnelle observée.

Le code Step 2 ne contient pas d'action terminale **ESCALATE**. Cette action est une extension pédagogique et une piste

future ; le benchmark gelé ne compare que GO, CONDITIONAL GO et NO-GO.

D.8 Le résultat mécanistique en image

Sur les 2 400 paires ED-POMDP contre cinq baselines, ED-POMDP obtient un meilleur Brier dans 1 119 cas. Pourtant, la décision reste identique dans 1 054 de ces cas.




FIGURE 5 – Une amélioration probabiliste n’est pas automatiquement une amélioration de décision.

D.9 Quels tests les politiques choisissent-elles ?




FIGURE 6 – Part des deux canaux sélectionnés par chaque politique sur l’ensemble du benchmark. La différence d’acquisition ne garantit pas une différence de décision.

D.10 Les données sont-elles représentatives, accessibles et statistiquement suffisantes ?

Question	Réponse bornée
Accessibles ?	Oui. Code, configuration, données brutes, hashes et analyses sont publiés dans le dépôt. Le fichier brut peut être régénéré exactement.
Reproductibles ?	Oui dans l'environnement spécifié. La reconstruction utilisée pour ces figures produit le SHA-256 officiel du fichier brut : <code>6695ab66...dd070</code> .
Représentatives d'un projet réel ?	Non au sens fort. Le monde comporte deux états binaires, deux canaux, des résultats binaires, des coûts unitaires, aucun changement de version et aucune organisation humaine.
Suffisantes pour Step 2 ?	Oui pour tester et finalement ne pas soutenir les claims larges dans ce monde synthétique gelé.
Suffisantes pour une preuve industrielle ?	Non. Elles ne permettent ni d'estimer des fréquences réelles de défauts, ni de calibrer les coûts, ni de démontrer une généralisation à d'autres produits.

Dans les 112 cellules ($4 \text{ conditions} \times 4 \text{ budgets} \times 7 \text{ politiques}$), le nombre de probabilités distinctes varie de 3 à 29, avec une médiane de 13. Le nombre d'intervalles de probabilités effectivement peuplés (les bins de l'ECE) varie de 2 à 10, médiane 6. Cela explique pourquoi une ECE calculée sur dix intervalles et trente seeds peut être numériquement correcte mais peu résolue.

Annexe E — De la seed au claim : la « moulinette » expliquée en français

Vue d'ensemble

La chaîne n'est pas une formule magique. Elle transforme successivement une configuration gelée en scénarios synthétiques, scénarios en observations, observations en croyances, croyances en décisions, décisions en métriques, métriques en comparaisons, puis comparaisons en une disposition de claim.

Étape	Transformation
1	<code>headline_matrix.json</code> fixe conditions, budgets, seeds, politiques, coûts, métriques et correction multiple.
2	<code>simulator.py</code> tire S , E et une bande de bruit déterministe à partir de la seed.
3	La politique choisit un canal uniquement à partir de l'historique observable.
4	<code>evidence_model.py</code> transforme (S, E, canal) en probabilité de FAIL, puis la bande de bruit produit PASS ou FAIL.
5	<code>decision.py</code> applique Bayes, calcule $P(S = \text{mauvais} \mid h)$, puis choisit GO, CONDITIONAL GO ou NO-GO selon la perte minimale.
6	<code>harness.py</code> écrit une ligne dans <code>headline_raw.csv</code> .
7	<code>metrics.py</code> calcule decision loss, Brier, ECE et unsafe GO ; il réalise bootstrap et permutation appariés.
8	Les 240 p-values confirmatoires sont corrigées par Holm.
9	<code>analyze_step28_mechanisms.py</code> relit les résultats gelés et explique pourquoi croyances et décisions divergent, sans créer de nouvelle inférence.
10	Le registre de claims enregistre le niveau de preuve, sa polarité et la disposition finale.

E.1 Exemple complet d'une ligne réelle

Pour la condition **identifiable**, budget 2, seed 0, politique ED-POMDP :

- le simulateur tire $S = \text{mauvais}$ et $E = \text{bon}$;
- la politique choisit deux fois le canal fonctionnel ;
- les deux observations sont FAIL : `functional:1;functional:1` ;
- la mise à jour donne $p = 0.7733537519$;
- comme $p > 3/11$, la décision est NO-GO ;
- le système étant réellement mauvais, le NO-GO n'ajoute aucune perte terminale ;
- le coût de preuve vaut $2 \times 0.1 = 0.2$, donc `decision_loss=0.2` ;
- le Brier vaut $(0.7733537519 - 1)^2 = 0.0513685218$;
- le risque résiduel attendu du NO-GO vaut $2(1 - p) = 0.4532924962$.

Cette ligne illustre la différence entre :

- la vérité latente, connue uniquement du simulateur ;
- la croyance, calculée à partir des observations ;
- la décision, choisie avec les pertes gelées ;
- la perte réalisée, calculée après comparaison à la vérité latente.

E.2 Comment les deux paris sont testés

Pari 1 — sélection de la prochaine preuve. Pour chaque condition, budget et seed, ED-POMDP est comparé aux plans fixe, aléatoire, entropie et risque seul. On demande si la différence

$$\Delta L = L_{\text{ED}} - L_{\text{baseline}}$$

est durablement négative. Une valeur négative signifie qu'ED-POMDP réalise une perte plus faible. Les comparaisons sont appariées seed par seed.

Pari 2 — représentation de la qualité de preuve. ED-POMDP est comparé au POMDP classique, qui marginalise E et ne peut pas apprendre que le canal fonctionnel est devenu plus ou moins fiable. On examine decision loss, Brier et ECE dans les conditions de preuve dégradée ou de modèle mal spécifié.

E.3 « Conditions », « cellules », « seeds » et autres mots traduits

Terme du dépôt	Traduction en français courant
Regime	Une condition expérimentale définissant comment le monde synthétique produit les observations.
Seed	Un numéro qui reproduit exactement le même scénario aléatoire.
Cell	Un groupe de trente épisodes partageant condition, budget et politique.
Posterior	La probabilité recalculée après les observations.
Baseline	Une stratégie de comparaison plus simple ou différente.
Endpoint	Une mesure finale utilisée pour juger le résultat.
Brier score	L'erreur quadratique d'une probabilité par rapport à la vérité binaire.
ECE	Un écart entre probabilités annoncées et fréquences observées dans des groupes de prédictions.
Bootstrap	Un rééchantillonnage des trente seeds pour mesurer la variabilité du résultat.
Permutation appariée	Un test qui échange aléatoirement les étiquettes ED/baseline au sein de chaque paire afin d'évaluer la rareté de la différence observée.
Holm	Une correction qui rend plus difficile la déclaration d'un résultat positif lorsque beaucoup d'hypothèses sont testées.
Confirmatoire	Prévu et gelé avant lecture des résultats ; peut gouverner le statut d'un claim.
Post-hoc descriptif	Analyse réalisée après les résultats pour comprendre un mécanisme ; elle ne crée pas rétroactivement une nouvelle preuve confirmatoire.

E.4 Documentation synthétique des modules

Fichier	Responsabilité
benchmark/config/headline_matrix.json	Contrat exécutable du benchmark : dimensions, politiques, coûts, métriques, seeds et règles statistiques.
benchmark/runtime/evidence_model.py	Table causale des probabilités de FAIL et modèle vrai mal spécifié.
benchmark/runtime/simulator.py	Génération déterministe des états latents et des observations ; les politiques n'accèdent jamais à la vérité.
benchmark/runtime/decision.py	Mise à jour bayésienne jointe $P(S, E h)$, décision terminale et calcul des pertes.
benchmark/runtime/ed_pomdp_policy.py	Choix du canal minimisant le risque terminal attendu plus le coût d'une observation.
benchmark/runtime/baseline_policies.py	Entropie, risque seul et POMDP classique sans état explicite de qualité de preuve.
benchmark/runtime/policies.py	Plans fixe, aléatoire et règle simple orientée échec.
benchmark/experiment/harness.py	Exécution appariée à horizon fixe et écriture des 3360 lignes brutes.
benchmark/analysis/metrics.py	Brier, ECE, bootstrap, permutation et Holm.
benchmark/analysis/analyze_step28_mechanisms.py	Diagnostic descriptif des différences de posterior, de seuil, d'acquisition et de décision.

E.5 Ce que le code ne fait pas encore

- Il n'apprend pas ses probabilités à partir de données industrielles.
- Il ne modélise pas un vecteur multidimensionnel de risques réels.
- Il ne modélise que deux canaux et des observations binaires.
- Il impose le même coût à chaque acquisition.
- Il interdit l'arrêt anticipé dans le benchmark confirmatoire.
- Il ne contient ni ESCALATE, ni acteur humain, ni délai organisationnel.
- Il ne représente pas explicitement des preuves corrélées, des versions changeantes, des données manquantes ou une dérive temporelle.

Condition minimale pour passer à un projet réel

Avant toute calibration industrielle, il faut démontrer que les variables observées, les labels de vérité, les coûts et les relations causales sont suffisamment gouvernés. Sans cela, ajouter davantage de mathématiques ne crée pas de connaissance : cela automatise seulement des hypothèses fragiles.

Annexe F — Comment juge-t-on un résultat ?

Pourquoi cette annexe est nécessaire

Le résultat central de Step 2 ne se résume pas à « une p-value est petite ». Il faut d'abord construire la probabilité qui sera évaluée, puis comprendre quatre opérations statistiques distinctes : mesurer sa calibration avec l'ECE, estimer la stabilité de l'effet par bootstrap apparié, tester sa rareté sous une hypothèse nulle par permutation, puis protéger l'ensemble des 240 comparaisons avec la procédure de Holm. Ces opérations répondent à des questions différentes ; leur combinaison explique pourquoi le seul signal confirmatoire reste intéressant mais fragile.

F.1 Avant la statistique : de $b(s)$ à la croyance jointe $b(s, e)$

Dans un POMDP classique simplifié, la croyance peut porter seulement sur l'état du système :

$$b(s) = P(S = s \mid h).$$

ED-POMDP ajoute une deuxième variable latente E , qui représente la qualité du dispositif produisant les preuves :

$$b(s, e) = P(S = s, E = e \mid h).$$

La croyance ne contient donc plus deux situations possibles, mais quatre :

$$(S \text{ bon}, E \text{ bon}), \quad (S \text{ bon}, E \text{ mauvais}), \quad (S \text{ mauvais}, E \text{ bon}), \quad (S \text{ mauvais}, E \text{ mauvais}).$$

Après une action a et une observation o , la mise à jour utilisée dans Step 2 est :

$$b'(s, e) = \frac{P(o \mid s, e, a)b(s, e)}{\sum_{s', e'} P(o \mid s', e', a)b(s', e')}.$$

Lecture en français. La probabilité nouvelle de chaque couple « état du système / qualité de la preuve » est égale à son ancienne probabilité, multipliée par la probabilité d'obtenir l'observation dans ce couple, puis divisée par la somme de tous les cas possibles.

Exemple numérique. Supposons un prior uniforme de 0.25 sur les quatre états et un FAIL sur le canal fonctionnel. Les probabilités de FAIL du modèle Step 2 sont 0.10, 0.60, 0.95 et 0.60 selon l'état.

État (S, E)	Prior	$P(\text{FAIL} \mid S, E)$	Masse brute	Posterior
bon, preuve bonne	0.25	0.10	0.0250	0.0444
bon, preuve mauvaise	0.25	0.60	0.1500	0.2667
mauvais, preuve bonne	0.25	0.95	0.2375	0.4222
mauvais, preuve mauvaise	0.25	0.60	0.1500	0.2667

La somme des masses brutes vaut 0.5625. Après normalisation :

$$P(S = \text{mauvais} \mid \text{FAIL}) = 0.4222 + 0.2667 = 0.6889,$$

$$P(E = \text{mauvais} \mid \text{FAIL}) = 0.2667 + 0.2667 = 0.5333.$$

Le même FAIL augmente fortement la croyance que le système est mauvais, mais il modifie aussi la croyance sur la qualité de la preuve. Une validation d'environnement ultérieure peut alors préciser si le FAIL fonctionnel était réellement discriminant ou produit par un dispositif dégradé.

Lien avec le pari 2

Le POMDP classique de Step 2 élimine E en le moyennant à son prior. Il peut estimer le risque système, mais il ne peut pas apprendre qu'une observation fonctionnelle devient plus ou moins fiable après une information sur l'environnement. ED-POMDP conserve cette dépendance dans $b(s, e)$.

F.2 ECE : une probabilité annoncée correspond-elle à la fréquence réelle ?

L'*Expected Calibration Error* regroupe les probabilités proches en intervalles, ou bins. Pour chaque bin k , on compare :

- $\text{conf}(k)$: la probabilité moyenne annoncée ;
- $\text{freq}(k)$: la fréquence réellement observée de l'événement ;
- n_k/N : le poids du bin dans l'échantillon.

La formule est :

$$\text{ECE} = \sum_{k=1}^K \frac{n_k}{N} |\text{conf}(k) - \text{freq}(k)|.$$

Lecture en français. Dans chaque groupe de prédictions proches, on mesure l'écart entre ce que le modèle annonce et ce qui arrive réellement, puis on fait une moyenne pondérée de ces écarts.

Exemple à trois bins.

Prédictions	Vérités observées	Calcul du groupe	Poids	Contribution
0.10, 0.15, 0.20	0, 0, 1	$ 0.15 - 0.333 $	3/10	0.055
0.40, 0.45, 0.50, 0.55	0, 1, 0, 1	$ 0.475 - 0.50 $	4/10	0.010
0.75, 0.80, 0.85	1, 1, 1	$ 0.80 - 1.00 $	3/10	0.060
ECE totale				0.125

Une ECE de 0.125 signifie ici un écart moyen pondéré de 12.5 points de pourcentage entre probabilités annoncées et fréquences observées.

Ce que l'ECE n'est pas.

- Ce n'est pas un taux de bonnes classifications.
- Ce n'est pas une erreur par épisode comme le Brier score.
- Elle dépend du découpage en intervalles et du nombre d'observations dans chacun.
- Deux modèles peuvent avoir la même ECE avec des distributions de probabilités très différentes.

F.3 La cellule qui porte le seul signal confirmatoire


Dans la condition « preuve dégradée », budget 2, ED-POMDP est comparé au POMDP classique sur les mêmes 30 seeds. Les intervalles sont figés par pas de 0.1.

Politique et intervalle	n_k	Confiance moyenne	Fréquence mauvaise	Contribution ECE
ED, [0.1, 0.2[	5	0.1435	0.4000	0.04275
ED, [0.4, 0.5[	13	0.4656	0.6154	0.06491
ED, [0.7, 0.8[	12	0.7734	0.5833	0.07601
ECE ED-POMDP				0.18367
Classique, [0.1, 0.2[	5	0.1070	0.4000	0.04883
Classique, [0.4, 0.5[	13	0.4339	0.6154	0.07864
Classique, [0.8, 0.9[	12	0.8306	0.5833	0.09891
ECE POMDP classique				0.22638

La différence observée est :

$$\Delta ECE = 0.183672 - 0.226380 = -0.042708.$$

Une valeur négative favorise ED-POMDP. Dans les trois groupes, ses probabilités moyennes sont plus proches de la fréquence observée.



Pourquoi la résolution est limitée. Les 30 probabilités de chaque politique ne prennent ici que trois valeurs distinctes et n'occupent que trois intervalles sur dix. Le plus petit en contient cinq : le passage d'un seul

résultat réel de 0 à 1 déplacerait sa fréquence de 0.20. L'ECE peut donc changer fortement lorsque quelques seeds sont davantage ou moins représentées.

Le point mécanique de fragilité

Ce n'est pas la formule de l'ECE qui est incorrecte. Le problème est la granularité de l'échantillon : peu de probabilités finales distinctes, peu d'intervalles peuplés et seulement trente scénarios indépendants par cellule. L'estimation est exacte pour ces données, mais sa stabilité hors de cet échantillon est incertaine.

F.4 Bootstrap apparié : l'effet résiste-t-il au changement de composition des seeds ?

Chaque seed produit une paire : un résultat ED-POMDP et un résultat baseline sur le même scénario latent et la même bande de bruit. Le bootstrap doit donc rééchantillonner des **paires complètes**, jamais les deux politiques séparément.

Pour un rééchantillonnage r :


1. tirer 30 indices de seeds avec remise ;
2. reconstruire les deux groupes avec exactement les mêmes indices ;
3. recalculer l'ECE ED et l'ECE baseline ;
4. enregistrer $\Delta ECE^{*(r)}$;
5. répéter 20 000 fois et prendre les quantiles 2.5% et 97.5%.

Pourquoi recalculer l'ECE ? L'ECE est une statistique de groupe, non une somme de petites ECE par épisode. Un rééchantillonnage change les fréquences et l'occupation des intervalles. Il serait incorrect de calculer une « ECE individuelle » puis d'en faire simplement la moyenne.

Pour la cellule centrale, l'intervalle percentile obtenu est :

$$[-0.046647, 0.003407].$$

Il traverse zéro : certaines compositions bootstrap des mêmes trente seeds ne conservent pas un avantage ED-POMDP.



Interprétation correcte. Le bootstrap ne dit pas « le résultat est faux ». Il montre que l'amplitude et même le signe de la différence sont sensibles à la composition d'un petit échantillon discret.

F.5 Permutation appariée : la différence serait-elle rare si les politiques étaient équivalentes ?

Le test de permutation pose l'hypothèse nulle suivante : dans chaque paire, les étiquettes « ED-POMDP » et « baseline » sont échangeables. Si les politiques sont équivalentes pour la métrique étudiée, inverser aléatoirement leurs résultats dans chaque seed ne devrait pas produire une distribution différente.

Pour chaque permutation :

1. pour chaque seed, conserver ou échanger les deux étiquettes avec probabilité 1/2 ;

2. recalculer les deux ECE et leur différence ;
3. compter les différences dont la valeur absolue est au moins aussi grande que la différence observée.

Le code utilise :


$$p = \frac{N_{\text{aussi extrême}} + 1}{R + 1}.$$

Le +1 évite de déclarer une probabilité exactement nulle avec un nombre fini de permutations.

Exemple minimal. Avec quatre paires dont toutes les différences favorisent ED, il existe seulement $2^4 = 16$ échanges possibles. Dans un test bilatéral, les configurations « toutes dans le sens observé » et « toutes inversées » sont aussi extrêmes : la p-value minimale est alors $2/16 = 0.125$. Même une direction parfaite ne suffit pas avec seulement quatre paires.

Dans Step 2, aucune des 50 000 permutations simulées n'a produit une différence aussi extrême que -0.042708 . Le calcul corrigé vaut donc :

$$p_{\text{brut}} = \frac{0 + 1}{50\,000 + 1} = 0.0000199996.$$



Pourquoi permutation et bootstrap peuvent-ils diverger ? Ils ne répondent pas à la même question :

- la permutation demande si la différence observée serait rare sous l'échangeabilité des étiquettes ;
- le bootstrap demande comment l'estimation varie lorsque la composition des seeds change.

Une statistique non linéaire et discrète comme l'ECE peut donc produire une p-value de permutation très petite tout en ayant un intervalle bootstrap qui traverse zéro. Ce n'est pas une contradiction mathématique ; c'est un avertissement sur la stabilité de l'estimation.

F.6 Holm : protéger la famille complète des 240 comparaisons

Tester une seule hypothèse au niveau $\alpha = 0.05$ autorise environ 5% de faux positifs lorsque l'hypothèse nulle est vraie. Tester 240 hypothèses séparément au même seuil crée de nombreuses occasions d'obtenir un résultat apparemment positif par hasard. À titre d'intuition, si les tests étaient indépendants et toutes les hypothèses nulles, la probabilité d'obtenir au moins un faux positif serait :

$$1 - (1 - 0.05)^{240} \approx 0.9999955.$$

La procédure de Holm contrôle le risque d'au moins une fausse déclaration dans la famille entière.

Algorithme de Holm.

1. trier les p-values : $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$;
2. comparer $p_{(1)}$ à α/m ;
3. si elle passe, comparer $p_{(2)}$ à $\alpha/(m - 1)$;

4. continuer en relâchant progressivement le seuil ;
5. s'arrêter au premier échec : cette hypothèse et toutes les suivantes ne sont pas rejetées.

Exemple jouet avec cinq hypothèses.

Rang	p-value triée	Seuil Holm	Résultat	Conséquence
1	0.003	$0.05/5 = 0.010$	passé	rejeter $H_{(1)}$
2	0.012	$0.05/4 = 0.0125$	passé	rejeter $H_{(2)}$
3	0.018	$0.05/3 = 0.0167$	échoue	arrêt
4	0.041	non testé	non rejeté	protégé par l'arrêt
5	0.200	non testé	non rejeté	protégé par l'arrêt

Bonferroni aurait utilisé le seuil fixe 0.01 et rejeté seulement la première hypothèse. Holm est donc au moins aussi protecteur, mais souvent plus puissant grâce à ses seuils progressifs.

Application exacte à Step 2. La plus petite p-value brute est celle de l'ECE, preuve dégradée, budget 2, ED-POMDP contre POMDP classique. Comme elle est première parmi 240 :

$$p_{\text{ajusté}} = 240 \times 0.0000199996 = 0.004799904.$$

Elle reste inférieure à 0.05. La comparaison suivante ne franchit pas son seuil, donc une seule hypothèse survit.

F.7 Pourquoi `unsafe_go_rate` reste hors de la famille confirmatoire

Le taux de GO dangereux est obligatoire et publié, mais il n'entre pas dans les 240 p-values. Cette décision a été prise avant les résultats confirmatoires.

Pour une variable binaire appariée, l'information du test provient surtout des paires **discordantes** : une politique produit un unsafe GO et l'autre non. Lorsque les deux politiques échouent ou réussissent sur les mêmes seeds, échanger les étiquettes ne change rien. Avec zéro paire discordante, la permutation est structurellement identique à l'observation et donne $p = 1$.

Le diagnostic pré-gel réalisé sur des seeds séparées montrait une discordance presque nulle. Ajouter de nombreuses hypothèses binaires non informatives aurait élargi la famille sans produire une inférence utile. Le protocole a donc retenu une règle plus honnête : publier tous les comptes absolus et réserver une future étude de sécurité à un plan spécifiquement dimensionné et préréglé.

Descriptif ne signifie pas secondaire

Le résultat sécurité 0, 0, 0, 17 contre 2, 2, 2, 18 reste visible et important. « Descriptif » signifie seulement que le protocole actuel ne permet pas de lui attribuer une conclusion de supériorité statistique correctement dimensionnée.

F.8 Lecture complète du seul contraste qui survit

Élément	Valeur et interprétation
ECE ED-POMDP	0.183672 : erreur de calibration agrégée plus faible.
ECE POMDP classique	0.226380.
Différence ED - classique	-0.042708 : effet observé favorable.
Intervalle bootstrap	$[-0.046647, 0.003407]$: traverse zéro, stabilité limitée.
p-value de permutation	0.0000199996 : différence très rare sous échangeabilité.
p-value ajustée de Holm	0.004799904 : survit à la famille de 240.
Décision finale	aucun contraste de decision loss ne survit ; le signal ne valide pas la supériorité décisionnelle générale.

La conclusion n'est donc ni « aucune information » ni « pari 2 prouvé ». La conclusion bornée est :

Dans une cellule synthétique précise, la représentation explicite de la qualité de preuve produit un signal d'amélioration d'ECE assez extrême pour survivre à Holm, mais sa stabilité bootstrap, sa faible résolution et l'absence de gain confirmatoire sur la perte de décision empêchent de promouvoir la forme large du claim.

F.9 Checklist pour juger un futur résultat

Avant d'accepter un résultat comme preuve, demander :

1. Quelle probabilité est évaluée : $P(S)$ ou une marginale issue de $P(S, E)$?
2. La métrique mesure-t-elle la précision, la calibration, la sécurité ou la décision ?
3. Combien d'unités réellement indépendantes composent chaque cellule ?
4. Les comparaisons sont-elles appariées sur les mêmes scénarios ?
5. Le bootstrap rééchantillonne-t-il les paires et recalcule-t-il la statistique complète ?
6. L'hypothèse nulle du test de permutation est-elle défendable ?
7. Combien d'hypothèses ont eu une chance de devenir positives ?

8. L'effet statistique modifie-t-il réellement la décision ou seulement la croyance ?
9. Le résultat survit-il à un changement de prior, de seuil, de coût ou de population ?
10. Le statut final est-il confirmatoire, descriptif ou exploratoire ?

F.10 Mini-révision

1. Dans la formule de l'ECE, pourquoi faut-il pondérer chaque intervalle par n_k/N ?
2. Pourquoi cinq épisodes dans un intervalle donnent-ils une fréquence observée par pas de 0.20 ?
3. Quelle différence de question sépare le bootstrap du test de permutation ?
4. Pourquoi le +1 apparaît-il dans la p-value Monte Carlo ?
5. Avec $m = 240$, quel est le premier seuil de Holm à $\alpha = 0.05$?
6. Comment une p-value ajustée peut-elle être inférieure à 0.05 tandis que l'intervalle bootstrap traverse zéro ?
7. Pourquoi une meilleure ECE ne démontre-t-elle pas automatiquement une meilleure décision GO / NO-GO ?

F.11 Références méthodologiques

- [1] G. W. Brier, « Verification of Forecasts Expressed in Terms of Probability », *Monthly Weather Review*, vol. 78, no 1, p. 1–3, 1950.
- [2] C. Guo, G. Pleiss, Y. Sun et K. Q. Weinberger, « On Calibration of Modern Neural Networks », *Proceedings of ICML*, 2017.
- [3] B. Efron et R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall/CRC, 1993.
- [4] R. A. Fisher, *The Design of Experiments*, Oliver and Boyd, 1935 ; E. J. G. Pitman, travaux fondateurs sur les tests de randomisation, 1937.
- [5] S. Holm, « A Simple Sequentially Rejective Multiple Test Procedure », *Scandinavian Journal of Statistics*, vol. 6, no 2, p. 65–70, 1979.
- [6] Dépôt ED-POMDP : `benchmark/analysis/metrics.py`, `benchmark/analysis/analyze_headline.py`, `benchmark/results/headline_contrasts.csv` et `benchmark/protocol/PREREGISTRATION.md`.